

CSE 454 – DATA MINING  
HOMEWORK #02

ANORMALLİK TESPİTİ İLE İLGİLİ  
ULUSLARARASI KONFERANS MAKALESİ RAPORU

GÖKHAN HAS  
161044067

Sosyal Ağ Analizinde Anormallik Tespiti  
için Veri Madenciliği Yaklaşımı

2. Uluslararası Yaratıcı İletişim ve  
Hesaplamalı Teknolojiler Konferansı  
(ICICCT 2018)

M.Swarna Sudha K.Arun Priya, A.Kanaka  
Lakshmi, A.Kruthika, D.Lakshmi Priya,  
Dr. Valarmathi K

## **KONFERANS HAKKINDA**

Daha gelişmiş bilgi işlem ve iletişim teknolojilerinin ortaya çıkışı, akıllı ev ve otomasyon, otomotiv, sağlık hizmetleri, lojistik, finans ve diğer akıllı şehir uygulamaları gibi günlük uygulama alanlarımıza yeni bir yol buluyor. Ortaya çıkan beşinci nesil iletişim sistemleri, yeni nesil iletişime yönelik dönüşümü türetmek için Bilgi Teknolojisi endüstrisi için yeni teknik içgörüler sağlar. Bu gelişmiş akıllı bilgi işlem ve iletişim teknolojilerindeki araştırma ilerlemesini teşvik etmek için, Hindistan'ın Namakkal şehrinde Gnanamani Teknoloji Koleji tarafından düzenlenen Uluslararası Akıllı Bilgisayar ve İletişim Teknolojileri Konferansı, yenilikçi bir forum olarak hizmet vermektedir ve gelişmiş akıllı bilgi işlem ve iletişim teknolojileri ile ilgili yenilikçi araştırma fikirlerini paylaşıldığı bir konferanstır.

## **ÖZET**

Günümüzde kullanıcılar; birçok kullanıcının, bir grubun veya belirli bir kuruluşun ağ üzerinden bağlı olduğu bir ağ olan Çevrimiçi Sosyal Ağlara daha fazla bağımlıdır. Çevrimiçi Sosyal Ağların kullanımı popülerdir ve bu nedenle kullanıcı davranışını inceleme ve anlama ihtiyacına neden olmuştur. Anormallik tespitinin tanımlanması üzerine çeşitli yaklaşımlar çalışmalar yapılmıştır. Bu yazıda ise, sosyal ağlardan anormallik tespiti için etkili bir yöntem öneriyoruz. Bu çalışma, sosyal medya uygulamasında farklı davranışlar sergileyen anormal etkinlikleri, davranış temelli anormallik algılama yaklaşımı kullanarak tespit etmeyi amaçlamaktadır. Anormal kullanıcılar, diğerlerinden davranışsal farklılıklarına göre tespit edilir. Aykırı değer tespiti için zengin bir veri kümesi önerilmiştir. Sonuçlar için görsel açıklama sağlamak için bir yöntem de önerilmektedir. Bu analiz, Facebook veri kümesi kullanılarak gerçekleştirilir.

## **GİRİŞ**

Teknolojinin gelişmesiyle birlikte, sosyal ağlarda kullanıcı davranışını incelemeye büyük bir ihtiyaç olduğu açıktır. ÇSA'ların kullanım ve faydalarının artmasıyla birlikte çeşitli zorluklar da ortaya çıkmaktadır. Günümüzde bu tür ağların karşılaştığı en büyük zorluklardan biri anormallik tespitidir. Kullanıcının davranışını analiz ederek tespit edilebilir. Kullanıcının davranışını belirlemek için çeşitli teknikler kullanılır. Mevcut sistem, kullanıcının içe dönük davranışını ve dışa dönük davranışını izlemeye devam etme temelinde davranışları farklılaştıran profil analizi yöntemini içermektedir. Ayrıca bağlantıda olan diğer kullanıcının en son güncellemelerini de görebilir. Mevcut yaklaşımlar, bilgisayar korsanının orijinal olandan kolayca ayırt edilebilmesi için kullanıcının sosyal davranışını profilleyerek kullanıcının çevrimiçi davranışını analiz eden yöntemi içerir. Profil oluşturma kullanıcının sosyal davranışı, kullanıcının güncellemelerinin analizini, kullanıcı tarafından gönderilen mesajların türünü, kullanıcı tarafından yapılan tıklama akışlarını, hesapta yüklenen fotoğraf türlerini, hesapta yapılan gönderileri, kullanıcının başkalarının gönderilerinde yaptığı yorumları vb. içerir. Makalemiz, davranışı normal kullanıcıdan farklı olan kullanıcının anormal davranışını tahmin etmek

için bir çözüm önermektedir. Anormallik, kullanıcının normal davranışından sapan bir dizi faaliyettir. Anomalilere aykırı değerlere, anormallikler de denir. Anormallik algılama, anormal verileri veri kümesinden kaldırmaya yönelik işleme tekniğidir. Bu nedenle, bu yazıda anormal davranışı analiz etmek ve tespit etmek için teknik anlatılmaktadır.

## VERİ MADENCİLİĞİ

Veri madenciliği, veri setlerinde depolanan büyük miktardaki veriden örüntüleri, ilişkileri, değişiklikleri ve anormallikleri keşfetme sürecidir. Keşif süreci, aşağıdaki adımların yinelenmeli bir sırasından oluşur:

*Veri Temizleme (Data Cleaning)* - Bu, koleksiyondaki gürültülü, hatalı, eksik veya ilgisiz verileri işler.

*Veri Entegrasyonu (Data Integration)* - Bu aşamada çoklu, heterojen ortak bir kaynaktan birleştirilir.

*Veri Seçimi (Data Selection)* - Analiz göreviyle ilgili veriler, veri kümesinden alınır.

*Veri Dönüşümü (Data Transformation)* - Verilerin dönüştürüldüğü yer, toplama işlemleri gerçekleştirilerek madencilik için uygun formlara konsolide edilir.

*Veri Madenciliği (Data Mining)* - Veri modellerini çıkarmak için akıllı yöntemlerin uygulandığı çok önemli bir adımdır.

*Örüntü Değerlendirme (Pattern Evaluation)* - Bu adımda, bilgiyi temsil eden ilginç kalıplar verilen ölçülere göre belirlenir.

*Bilgi Temsili (Knowledge Representation)* - Bu, mayınlı bilgiyi kullanıcıya sunmak için görselleştirme ve bilgi temsil tekniklerinin kullanıldığı son bir aşamadır.




Fig II: Data mining process

## YAPILAN ÇALIŞMALAR

Anormallik tespiti olgun bir araştırma alanıdır. Ağ saldırı tespiti, kredi kartı sahtekarlığı tespiti, e-posta tabanlı ağ analizi vb. çeşitli alanlarda başarıyla uygulanmıştır. Anormallik algılama algoritmaları, normal davranışın anormal davranıştan daha baskın olduğu ve çoğunluk tarafından sergileneceği varsayımıyla çalışır. Wasserman ve Faust, sosyal ağ analizi için merkezîyet temelli önlemlerin

kullanılmasını önerdi. Lin ve Chalupsky, posta veri kayıtlarından anormal aboneleri tespit etmek için dolaylı bağlantıların kullanılmasını önermişlerdi. Chalupsky, bunu VAST 2008 sorununu çözmek için kullandı. Önceki araştırma çalışmaları bunu çoğunlukla bir sınıflandırma görevi olarak görse de, biz bunu bir anormallik algılama sorunu olarak ele alıyoruz. Yanlış söylentiler anormallik olarak görülüyor ve bu anormallikleri tespit etmek için önerilen özelliklerimizdeki karışık verilerin faktör analizini yapıyoruz. Sapma derecesini tanımlamak için Öklid mesafesine ve kosinüs benzerliğine dayalı iki strateji önerilmektedir. Sapma derecesine dayalı bir sıra hesaplanır ve bu, daha fazla söylenti tespitini kolaylaştırabilir. Yöntemimizin iyi performans elde edebileceğini ve çevrimiçi sosyal ağlarda yanlış söylentilerin otomatik olarak tespit edilmesine ışık tutabileceğini gösteriyoruz.

## **ANORMALLİK TESPİTİ İÇİN VERİ MADENCİLİĞİ YAKLAŞIMLARI**

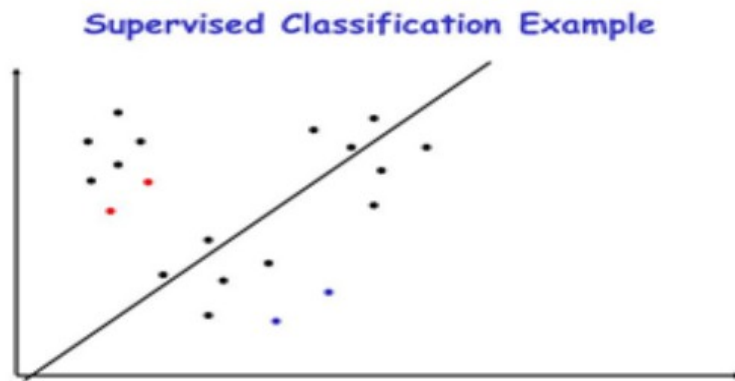
Anomali tespiti, “diğer gözlemden çok sapan bir gözlem” olarak tanımlanır. Veri madenciliği perspektiflerinden, anormallik tespiti aşağıdaki kategorilere ayrılır:

- Denetimli yöntem (Supervised method)
- Yarı denetimli yöntem (Semi-supervised method)
- Denetimsiz yöntem (Unsupervised method)

### **A) DENETLENEN YÖNTEM (SUPERVISED METHOD)**

Normal veya anormal olarak etiketlenmiş önceden etiketlenmiş verilerle bir sınıflandırma problemi olarak anormallik tespitini incelemeyi içerir. Bu yöntemler hem normal hem de anormal davranışları modellemektedir. Bunun için uygulanabilir iki yaklaşım vardır.


- Birincisi, uzmanlar normal verileri önceden etiketleyebilir ve bu modele benzemeyen bu tür veriler anormal olarak kabul edilir.
- Diğer yol ise tersini yapmaktır, yani önceden tanımlanmış anormal veri kümesine sahip olmak ve anormal veri kümesine karşılık gelmeyen nesneler normal kabul edilir.



## B) YARI DENETİMLİ YÖNTEM (SEMI-SUPERVISED METHOD)

Modelin normal veriler kullanılarak eğitildiği yarı denetimli yöntem, yalnızca normal aktivite profilini oluşturmak için kullanılır. Yarı denetimli yöntemler, etiketli ve etiketsiz olmak üzere iki veri setiyle çalışır. Bu nedenle, bu yöntemler, tam veri kümesinin dışında yalnızca normal olarak etiketlenmiş birkaç veri örneği mevcut olduğunda kullanılır. Az miktarda etiketli veri kullanılarak, daha sonra etiketlenmemiş verileri etiketlemeye çalışan bir sınıflandırıcı oluşturulabilir. Bu nedenle, normal modele uymayan nesnelerin anormallik olarak sınıflandırılacağı şekilde anormallikleri tespit etmek için kullanılan bir model oluşturulur. Bu, yarı denetimli model altında kullanılan kendi kendine eğitim adı verilen en basit yaklaşımdır.

Semi-Supervised Clustering Example




## C) DENETİMSİZ YÖNTEM (UNSUPERVISED METHOD)

Anormallik algılama modelinin hem normal hem de anormal verilerden oluşan etiketlenmemiş veriler kullanılarak eğitildiği denetimsiz yöntemlerdir. Denetlenmemiş anormallik algılama yöntemleri, etiketli veri nesneleri mevcut olmadığında kullanılır, yani veri nesnelerine "anormallik" veya "normal" olarak önceden tanımlanmış etiketler eklenmediğinde bulunur. Denetimsiz yöntemler genellikle bir kümeleme problemi olarak incelenir. Gruptaki nesneler birbirine benzer ve diğer gruptaki nesnelerden farklı olacak şekilde nesne grubunu bulmak amaçlanır.

Denetimsiz yöntemlerin karşılaştığı iki büyük zorluk şunlardır:

- İlk olarak, herhangi bir kümeye ait olmayan bir veri nesnesi anormal olarak kabul edilir, ancak bu tür bir veri nesnesi bir anormallikten ziyade bir gürültü olabileceğinden çoğu kez bu tartışma yanlış olabilir.
- İkinci olarak, genellikle uygulanan şey, önce kümeleri ve sonra anormallikleri bulmaktır. Ancak bir veri kümesinde bulunan anormalliklerin sayısı normal veri nesnelerinden oldukça az olduğu için bu yöntem oldukça pahalı görünmektedir.

## Unsupervised Clustering Example



## ANORMALLİK TESPİT TEKNİKLERİ

Sosyal ağlarda, diğer düğümlerden sapan davranışı takip ederek bu benzerlik ölçütlerine uymayan düğüm anormal olarak algılanır. Sosyal ağlarda anormallik tespit teknikleri şu şekilde kategorize edilebilir:

- Davranış temelli teknikler (Behavior based)
- Yapısal (grafik) tabanlı teknikler (Structural (graph) based)
- Spektral tabanlı teknikler (Spectral based)

### A) DAVRANIŞ TABANLI TEKNİKLER (BEHAVIOR BASED)

Davranış temelli teknikler, kullanıcıların mesaj sayısı ve içeriği, paylaşılan öğelerin içeriği, bir gönderideki beğeni veya yorum sayısı ve bir sohbetin süresi gibi davranış özelliklerini ele alır., Paylaşılan, bir gönderideki beğeni veya yorum sayısı ve bir konuşma süresinin zamanı olabilir.

### B) YAPISAL TEMEL TEKNİKLER (STRUCTURAL BASED)

Yapısal tabanlı yöntemler, normal ve anormal kullanıcıların özelliklerini kontrol etmek için yapısal özellikleri kullanma temel prensibi üzerinde çalışır. Farklı düğümler ve yapılar için belirli bir grafik ölçütü oluşturulur ve diğer kullanıcılardan farklı değerler gösteren düğümler anormal olarak kabul edilir. Denetimli yaklaşım gibi, burada da önceden tanımlanmış bir normal model zaten bilinmektedir ve bu bilinen modelden herhangi bir sapma anormal davranışı tasvir eder. Bu teknikler, gelecekteki olayları tahmin ederek ve dinamik anormallikler için bir ön koşul olan önceki ağ davranışını analiz ederek dinamik etiketlenmemiş anormalliklerin belirlenmesine yardımcı olur.

### C) SPEKTRAL (ÖZEL) BAZLI TEKNİKLER (SPECTRAL BASED)

Spektral anormallik tespit teknikleri, grafiğin spektral uzayındaki bazı spektral özellikleri kullanarak anormallikleri tespit etmeye yardımcı olur.

## **KULLANICI DAVRANIŞINA DAYALI RİSK DEĞERLENDİRMESİ**

Ana hedefimiz, çevrimiçi sosyal ağlarda nasıl davrandığına bağlı olarak kullanıcıyla bir risk puanı ilişkilendirmektir. Temel fikir, kullanıcı davranışının normal bir davranış olarak kabul edilen davranıştan ne kadar farklı olursa, riskli olarak kabul edilmesi gerektiğidir. Bu nedenle, önce bir kullanıcı davranış profili tanımlıyoruz.

Çevrimiçi bir sosyal ağda, gönderi, yorum, paylaşma, beğenme ve farklı etkileşim türleri gibi çeşitli etkinlikler mümkündür. Bu davranış profilini tasarlarken, tüm kullanıcıların etkinliklerini izlemeye gerek yoktur. Ancak yalnızca riskli davranışları ortaya çıkarabilecek olanlar izlenir. Örneğin, herhangi bir beğeni almadan daha fazla yorum / gönderi yazmak. Bir uyarı olarak düşünebilir ve bir saldırıya uğrayabilirler. Aksine kısa sürede çok sayıda arkadaş, gönderi, yorum, beğeni sahibi olmak da riskli olarak değerlendiriliyor. Çevrimiçi sosyal ağ popülasyonu, gözlemlenen davranışta heterojendir, bu nedenle tüm çevrimiçi sosyal ağ kullanıcı davranışlarına uyan benzersiz standart davranış modelini tanımlamak mümkün değildir.

Bununla birlikte, benzer kişilerin benzer davranış modeliyle sonuçlanan benzer kuralları takip etme eğiliminde olmasını bekliyoruz. Bu nedenle, iki aşamada organize edilmiş risk değerlendirmesi öneriyoruz: İlk aşama, çevrimiçi sosyal ağdaki grupları tanımlamayı amaçlamaktadır. Bu, kümeleme teknikleriyle elde edilir. İkinci aşama, birinci aşama ile belirlenen her grup için davranışsal model oluşturmayı amaçlamaktadır.

## **ÇEVİRİMİÇİ SOSYAL AĞLARDA RİSKLİ DAVRANIŞLAR**


Sosyal ağ sitelerinin popüleritesi nedeniyle, siber suçlular veya saldırganlar kötü amaçlı yazılımları yaymak ve dolandırıcılık yapmak için onları sövmeye başladı. Tutarsızlık (discrepancy) sıklık, sayı ve faaliyetlerin türü açısından tanımlanır. Genel olarak, saldırganlar, bir kullanıcı ve arkadaşları hakkında kişisel bilgileri toplamak ve ifşa etmek, kullanıcıyı ağda yaymak için bazı belirli kötü amaçlı bağlantıları tıklatmaya zorlayarak çevrimiçi sosyal ağ altyapısını kullanır. En dikkat çekici saldırı türlerine Sybil Saldırısı, Kimlik Klon Saldırısı ve Yazılım Saldırıları örnek verilebilir.

## **METODOLOJİ**

Metodolojimiz, veri setinin toplanması, boş değerlerin çıkarılması, verilerin kategorize edilmesi, kümeleme, risk analizi gibi kavramlar üzerinden ilerlemektedir.


1. Bir veri kümesi, tek bir veritabanı tablosunun içeriğine karşılık gelen bir veri koleksiyonudur.
2. Veri kümesinden boş değerleri kaldırılmalıdır.
3. Risk değerlendirme yaklaşımı, kullanıcının davranışının normal kullanıcıdan ne kadar farklı olduğuna bağlı olarak kullanıcının riskini tahmin etme fikrine dayanmaktadır. Risk değerlendirmesi iki aşamalı kümelemeden oluşur:
  - İlk aşama, kullanıcıların grup tanımlama özelliklerine göre organize edilmesinden oluşur.

- İkinci aşamada, kullanıcılar K-means ve Expectation Maximization algoritması kullanılarak davranışsal özellikler yardımıyla kategorize edilir.
4. Risk puanı, grup tanımlama özelliklerinin bir değerine dayalı olarak Üyelik olasılığı kullanılarak tahmin edilir.
- Yüksek üyelik olasılığı - normal kullanıcı.
  - Düşük üyelik olasılığı - anormal kullanıcı.



## KÜMELEME

Kümeleme, bir dizi veriyi özelliklerine göre kümelere ayırma görevidir. Görüntü işleme ve veri analizi için yapılan örüntü tanıma'da (pattern recognition) kullanılır. Yüksek boyutlu verilerdeki yapıları ve kalıpları keşfeder.



### A) K-Means Kümeleme Algoritması

K-Means,  $n$  nesneyi özniteliklere dayalı olarak  $k > n$ 'nin olduğu  $k$  bölümlere ayıran en basit denetimsiz öğrenme algoritmasından biridir.

Amaç, verilerde  $K$  değişkeni ile temsil edilen grupların sayısı ile grupları bulmaktır.

Adım 1 - Başlatma: Veri kümesinden rastgele  $k$  vektör seçin ve bunları ilk küme merkezleri yapın.

Adım 2 - Atama: Her vektörü en yakın merkezine atayın.

Adım 3 - Güncelleme: Her merkezi, üyelerinin ortalamaları ile değiştirin.

Adım 4 - Yineleme: Güncelleme kalmayana kadar 2. ve 3. adımları tekrarlayın.



## B) ANORMALLİK TESPİTİ

Bu yazıda önerilen anormallik algılama algoritması, aykırı değer tespiti ilkesine dayanmaktadır. Bir veri kümesindeki bir aykırı değer, farklı bir mekanizma tarafından oluşturulduğuna dair şüpheler uyandıracak şekilde diğer gözlemlerden çok fazla sapan bir gözlem olarak tanımlanır. Çoğu gerçek senaryoda aykırı değerler, daha sık meydana gelen gözlemler tarafından büyük ölçüde geride bırakılır. Aykırı değerleri belirlemeye yönelik denetimsiz yaklaşımlar, büyük veri kümelerinden anormallikleri veya uygun olmayan varlıkları tespit etmede yararlıdır. Bu yazıda, aşağıdaki gibi bir aykırı değer tanımlanmıştır:  
Tanım: Bir kümenin aykırı değerleri, en yakın komşularından en uzaktaki ilk n veri ögesidir.

## KUTU DİYAGRAMI (BOX PLOT)

Medyan değerini belirtmek için dörtte birlik kısımlar ve içerideki dikey çizgi boyunca sayısal veri gruplarını tasvir etmek için dikdörtgen içinde bir arsa üzerinde istatistiksel verileri temsil etme yöntemidir.

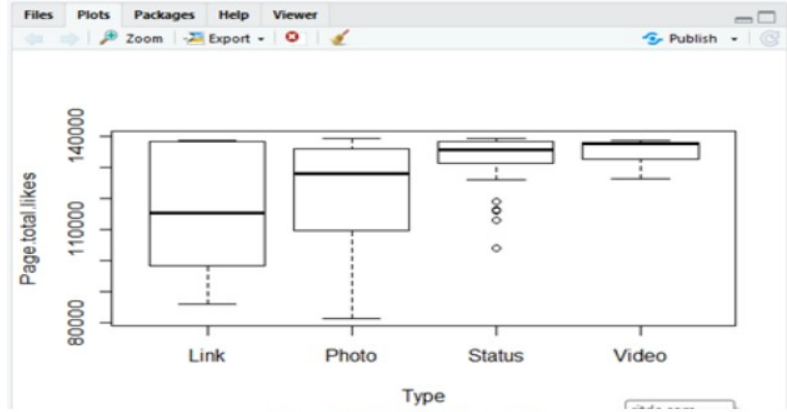


Fig IX: A(1) Box plot

## AYKIRI DEĞERLER (OUTLIERS)

Diğer gözlemlerden uzak bir gözlem noktasıdır. Ölçümdeki deneysel hatayı veya değişkenliği gösterebilir. İstatistiksel analizde sorun yaratabilir.

Aykırı değerler, verilerdeki diğer gözlemlerden sapan uç değerlerdir, bir ölçümde, deneysel hatalarda veya bir yenilikte bir değişkenliği gösterebilir. Başka bir deyişle, aykırı değer, bir örneklem üzerindeki genel modelden farklılaşan bir gözlemdir.

## ÇUBUK GRAFİK (HISTOGRAM)

Histogram, matematikte, özellikle istatistikte yaygın olarak kullanılan bir grafik türüdür. Histogram, ardışık ve sabit aralıklarla düzenlenmiş belirli bir değer aralığında yer alan belirli olayların meydana gelme sıklığını temsil eder. Verilerin oluşma sıklığı bir çubukla temsil edilir Bu, sayısal verilerin dağılımının doğru bir temsidir. Sürekli bir değişkenin olasılık dağılımının bir tahminidir.

## DENEYSEL SONUÇLAR

Önerilen yaklaşım, R programlama kullanılarak yüz kitap veri kesindeki toplam etkileşim sütunu dikkate alınarak test edilmiştir. Toplam etkileşim sütununun maksimum ve minimum sapmaları histogram ile tanımlanmıştır. Daha sonra minimum sapma değerleri, kutu grafiği kullanılarak aykırı değerler olarak çıkarılır. Kutu grafiği, tüm aykırı değerler kaldırılacak şekilde doğrulanmalıdır. Şimdi, mevcut veriler için histogram çizilmiştir ve sonunda çubuk grafikleriyle gösterilmiştir.

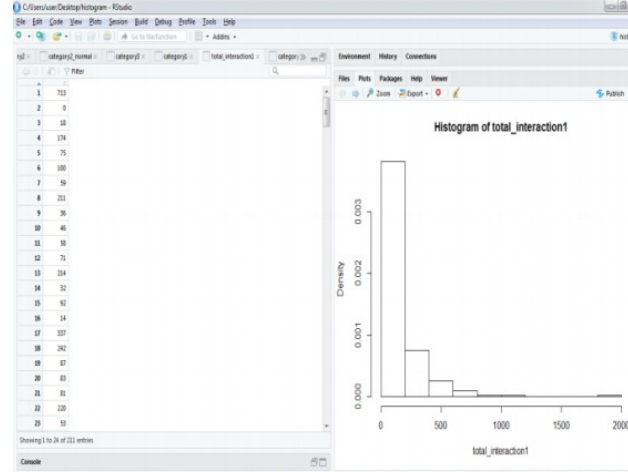


Fig : X(1) Histogram for Total interaction column




Fig : X(2) Box plot to identify the outliers

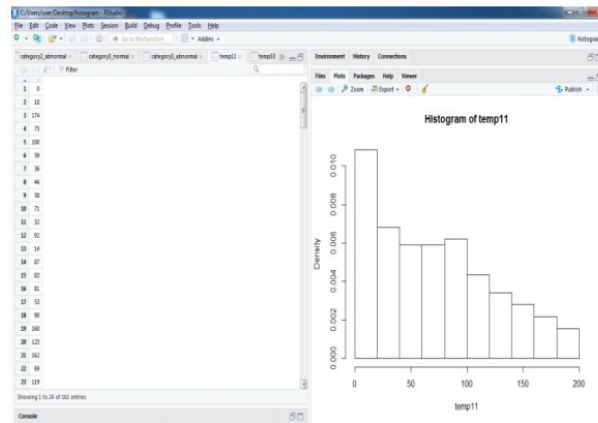


Fig : X(3) Histogram for the same Total interaction column with removed outliers

## **SONUÇ**

Bu yazıda, aykırı değer tespiti kullanarak anormal kullanıcıları diğerlerinden davranışsal farklılıkları temelinde tespit etme yöntemi önerilmiştir. Sonuçlar için görsel açıklama sağlamak için bir yöntem de önerilmektedir. Bu analiz, her ÇSA kullanıcıasına risk puanı atayan Facebook veri kümesi kullanılarak gerçekleştirilir. Bu değerlendirme, kullanıcı davranışına dayalı olarak daha fazla kullanıcı davranışının farklılaşması fikri altında, riskli olarak değerlendirilmektedir. Bu analiz, tahminimizin etkinliği için Facebook veri kümesinde yapılmıştır.

## **MAKALENİN LİTERATÜRE KATKISI**

Bu okumuş olduğum makalede anormallik tespiti problemine yeni bir metod uygulayarak çözüm önerilmiştir. Çevrimiçi sosyal ağlar üzerinde çalışılarak metodlar uygulanmıştır. Böylece çevrimiçi sosyal ağlardaki anormallik tespiti konusunda araştırmacılara farklı bir bakış açısı kazandırmıştır. Ayrıca günümüzde neredeyse herkes tarafından kullanılan, bunların birlikte gelir kaynağının fazla olması, son kullanıcıya ulaşmanın çok kolay ve az maliyetlerin olduğu çevrimiçi sosyal ağları konu alarak yapılacak olan araştırmalara teşvik ettiğini düşünüyorum. Ayrıca Facebook veri kümesini kullanarak ortaya daha doğru sonuçların konulduğunu düşünüyorum. Bu uygulanan yöntemler gerçek hayatta mevcut eski yöntemlerden daha etkilidir. Bu da önceden yapılan çalışmaları, bu yöntem ile tekrardan yapıldığında daha fazla sonuçlar verebilir ve bu problem üzerinde hala çalışmalar yapılarak gelişime açık olduğu izlenimi vermektedir. Ekstra olarak yapılan çalışmaların sonuçlarının araştırmacıya daha güzel ve etkili bir biçimde çeşitli grafik türleri ile gösterilmesi olumlu katkı sağlamıştır. Problemin çözümü için ortaya atılan yöntemler araştırmacının daha kolay anlayabilmesi adına basit ve sade bir düzeyde tutulmuştur. Bu da konu hakkında hiç bilgisi olmayan bir araştırmacının da çözüm yöntemleri ve konu ile ilgili bir izlenime sahip olmasını kolaylaştırır. İyi bir başlangıç yazısı olduğunu düşünmekteyim.